

江苏海洋大学
JIANGSU OCEAN UNIVERSITY

本科毕业设计（论文）

基于深度学习的海洋锋检测方法研究

Research on Ocean Thermal Front Detection Methods Based on Deep Learning

学 院：	海洋技术与测绘学院		
专业班级：	海洋技术 海技 1221		
学生姓名：	游康林	学 号：	2022120509
指导教师：	查国震（副教授） 吴立宗（高级工程师）		

2026 年 6 月

江苏海洋大学

毕业设计（论文）原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日期： 年 月 日

江苏海洋大学

毕业设计（论文）版权使用授权书

本毕业设计（论文）作者同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权江苏海洋大学可以将本毕业设计（论文）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本毕业设计（论文）。

作者签名：

指导教师签名：

日期： 年 月 日

日期： 年 月 日

毕业设计（论文）中文摘要

基于深度学习的海洋锋检测方法研究

摘 要：海洋锋是海洋中两种有明显要素差异的水团交汇时形成的狭长过渡带，对海洋环境、海洋气候及水下声传播都有重要影响。本文收集了 2022 年 1 月至 6 月的中国南海中南部海域的全球高分辨率四级海表温度数据，利用 Sobel 算子提取候选温度锋，并开展人工筛选、矩形框标注与数据集划分等工作，构建海洋温度锋目标检测数据集。在此基础上，发展了基于 YOLO11 模型的海洋温度锋检测方法，并分析学习率、输入尺寸和批量大小（batch size）对识别精度的影响。实验结果表明，当学习率为 0.0006、输入尺寸为 512、batch size 为 4 时，模型综合表现较好。最终模型在测试集上取得精确率（Precision）为 0.62458、召回率（Recall）为 0.67692、交并比阈值为零点五时的平均精度均值（mAP@0.5）为 0.60208、交并比阈值从零点五到零点九五时的平均精度均值（mAP@0.5:0.95）为 0.26980 的结果。研究表明，YOLO11n 能够对海表温度图像中的部分温度锋区域进行有效识别，但在弱锋面、复杂背景及精细定位方面仍存在进一步提升空间。

关键词：海洋锋；温度；YOLO；目标检测；

毕业设计（论文）外文摘要

Research on Ocean Thermal Front Detection Methods Based on Deep Learning

Abstract: Ocean fronts are narrow transitional zones formed where two water masses with distinct hydrographic properties converge. They have important impacts on the marine environment, ocean climate, and underwater acoustic propagation. In this study, GHR SST Level 4 sea surface temperature data from the South China Sea from January to June 2022 were collected. The Sobel operator was used to extract candidate thermal fronts, followed by manual screening, rectangular bounding-box annotation, and dataset partitioning, thereby constructing an object detection dataset for ocean thermal fronts. On this basis, an ocean thermal front detection method based on the YOLO11 model was developed, and the effects of learning rate, input image size, and batch size on detection accuracy were analyzed. The experimental results show that the model achieved relatively good overall performance when the learning rate was 0.0006, the input image size was 512, and the batch size was 4. The final model achieved a Precision of 0.62458, a Recall of 0.67692, an mAP@0.5 of 0.60208, and an mAP@0.5:0.95 of 0.26980 on the test set. The results indicate that YOLO11n can effectively identify some thermal front regions in sea surface temperature images, but there remains room for further improvement in detecting weak fronts, handling complex backgrounds, and achieving precise localization.

Keywords: ocean front; temperature; YOLO; object detection

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	1
1.3 本文主要工作.....	4
1.4 本文章节安排.....	4
2 数据集构建.....	6
2.1 研究区域.....	6
2.2 GHR SST Level 4 海表温度数据介绍	6
2.3 研究区域数据裁切.....	7
2.4 海洋温度锋目标标注.....	11
3 YOLO11n 模型简介	13
3.1 卷积神经网络简介.....	13
3.2 YOLO 模型简介	13
3.3 模型评价指标.....	15
4 基于深度学习的海洋锋检测方法.....	16
4.1 实验环境.....	16
4.2 基于 yolo11 的海洋锋检测方法.....	17
4.3 实验结果评估.....	23
结论与展望.....	28
致 谢.....	30
参 考 文 献.....	31

基于深度学习的海洋锋检测方法研究

1 绪论

1.1 研究背景与意义

海洋锋是海洋中不同性质水团相互接触和作用时形成的过渡区域，在锋面附近，海水的温度、盐度、密度、水色等要素通常会在较小空间范围内发生明显变化，并表现出较强的水平梯度特征。其中，海洋温度锋是较为常见的一类海洋锋，主要表现为表层海水温度在一定区域内快速变化，本质上是不同温度水团之间形成的温度过渡带。

海洋温度锋检测不仅具有海洋科学研究价值，也和一些实际应用有一定联系。锋区还可能使海面漂浮物、油污、微塑料等在局部区域聚集，对海洋环境监测和污染物追踪也有一定帮助。同时，海水温度变化会影响水下声速结构，进而影响水声通信、水下目标探测和定位等工作。如果温度锋位置掌握不准确，可能造成探测距离变化、回波不稳定、定位误差增大等问题。此外，锋区附近的热量交换和海气相互作用较为活跃，也可能与局地海雾、海上天气变化等现象有关。因此，对海洋温度锋进行快速、准确的检测，可以为渔业生产、海洋环境监测、海上活动保障和水下信息获取等提供基础参考。

近年来，机器学习和深度学习被逐步引入海洋遥感图像识别任务，并开始用于海洋温度锋检测研究。与依赖人工设定阈值的方法相比，卷积神经网络可以从样本图像中学习锋面区域的边缘、纹理和空间分布特征，从而降低对固定阈值和人工经验规则的依赖，不过此类方法在复杂背景下的识别效果仍然需要通过实验结果验证。因此，本文尝试将 YOLO11n 目标检测模型应用于海洋温度锋检测，将温度锋区域作为检测目标进行定位，以探索目标检测方法在海洋温度锋自动识别中的适用性。

1.2 国内外研究现状

目前，海洋温度锋检测方法大致可分为传统特征检测方法和基于机器学习、深度学习的智能检测方法。传统检测方法通常包括阈值法、梯度法和局部直方图特征分析法等，主要通过提取海表温度场中的温度突变或梯度变化来识别锋面。这类方法原理清楚、实现成本较低，但检测结果通常依赖阈值设置和局部特征质量。当海表温度图像受到云遮挡、噪声干扰、近岸复杂背景或弱锋面影响时，方法稳定性容易下降，并可能出现误检或漏检，难以适应复杂海况条件下的自动化检测需求。

1.2.1 传统海洋温度锋检测技术研究现状

国内外学者在利用传统方法检测海洋锋上做了大量工作，其主要工作主要可以概括为以下几点：包括基于梯度与边缘检测的锋面识别方法、基于局部直方图的锋面检测方法，以及基于统计模型、引力模型和区域遥感分析的海洋锋研究方法。传统方法通常利用海表温度（SST）在空间上的突变特征、水团分布差异或统计特征实现锋面识别，具有原理清晰、计算过程相对简单和可解释性较强等特点，在海洋温度锋候选区域提取和海洋锋时空分布研究中得到了广泛应用。

在基于梯度和边缘检测的海洋锋检测研究中，Cayula 和 Cornillon 较早提出了一种面向卫星海表温度图像的自动边缘检测算法^[1]，该项方法通过图像级、窗口级和局部级三个层次进行判断，通过分析局部海表温度分布差异来识别温度锋位置，与单纯依赖固定阈值的方法相比，该方法不直接以锋面绝对强度作为唯一依据，而是结合局部背景判断锋面相对强度，该方法在一定程度上减少了固定阈值带来的误检问题。随后，Cayula 和 Cornillon 进一步提出多图像边缘检测方法，通过分析连续 SST 图像序列，提高温度锋检测稳定性^[2]。Belkin 和 O' Reilly 提出 BOA 算法，将梯度思想应用于 SST 遥感图像处理中，在滤除噪声的同时较好地保留了锋面结构^[2-3]。国内方面，黎安舟等对遥感图像中尺度海洋锋及涡旋提取方法进行了综述，指出梯度法、Sobel 算法和 Canny 算法是遥感图像锋面提取中的常见方法，其中 Canny 算法在锋面连续性和边缘提取精度方面具有一定优势^[4]。于杰、管磊基于 SNPP/VIIRS 卫星海表温度数据，对 Sobel 算法、Canny 算法、引力模型法、直方图分析法和熵算法进行了对比研究^[5]，研究表明，Canny 算法和引力模型法对强锋面的检测能力较强，熵算法在弱锋面识别方面具有一定优势，直方图分析法得到的锋面结果相对连续、平滑，抗噪性较好。由此可见，不同海洋温锋检测算法的适用场景也不相同，实际应用时应根据研究目标、锋面强度和噪声情况选择相应方法。

在基于局部直方图的海洋锋检测研究中，相关方法通常利用局部窗口内 SST 值的统计分布特征，判断窗口内是否存在性质不同的水团。当窗口内温度分布呈现较明显的双峰结构时，通常表明该区域可能包含两个温度特征不同的水团，其过渡区域可作为候选锋面。Cayula-Cornillon 算法是该类方法的代表方法之一，其特点是结合局部温度分布和上下文信息进行锋面判断，而不是单纯依赖固定梯度阈值^[1]。在此基础上，Kirches 等提出 GRADHIST 方法，将 Canny 梯度检测思想与 Cayula-Cornillon 直方图方法相结合，用于多种海洋遥感参数和不同传感器数据中的锋面检测^[6]。国内研究中，李阳东等针对低质量、噪声较多的遥感海表温度图像，提出

结合直方图分析与 Jensen-Shannon 散度的海表温度锋检测方法，以改善复杂图像条件下温度锋的提取效果^[7]。

在基于统计模型、引力模型以及区域遥感分析的海洋锋研究中，国外学者 Hopkins 等提出基于 AVHRR SST 图像的海洋锋统计建模方法^[8]。国内方面，吴曲然等对海洋锋统计模型检测法进行了改进与验证^[9]；平博等提出基于引力模型的海洋锋信息提取方法^[10]；王磊等和陈彪等则分别对南海北部陆架、琼东和粤西等海域海表温度锋的时空变化特征进行了分析研究^[11-12]。

总体来看，传统海洋温度锋检测方法具有原理清楚、实现相对简单和可解释性较强等优点，但也存在一定局限性。一方面，这类方法通常依赖人工经验设置阈值；另一方面，对云层、噪声、陆地边界以及近岸复杂背景较为敏感，在弱锋面、断续锋面和复杂温度背景条件下容易出现误检或漏检。因此，在复杂海况条件下，传统方法往往需要结合更加自动化和数据驱动的方法进行进一步改进。

1.2.2 基于深度学习海洋温度锋检测技术研究现状

国内外学者在基于深度学习的海洋锋检测方法研究上做了大量工作，其主要工作主要可以概括为以下几点：包括基于卷积神经网络的锋面识别方法、基于深度边缘检测的锋面提取方法、基于语义分割与实例分割的海洋锋检测方法，以及基于轻量化网络或目标检测模型的锋面检测方法。相比传统方法，深度学习方法能够自动学习海洋温度锋的纹理、边缘及空间结构特征，在复杂背景、弱锋面以及多尺度锋面识别方面具有较强优势。

在基于卷积神经网络的锋面识别方法的研究中。这类方法利用卷积神经网络对海表温度图像中的纹理、边缘及空间结构特征进行自动提取，从而实现海洋锋识别。国外研究中，Lima 等较早将卷积神经网络与迁移学习应用于海洋锋识别任务，研究表明深度学习方法能够减少对人工特征和固定阈值的依赖，提高锋面识别的自动化程度^[13]。

在基于深度学习边缘检测的海洋锋提取研究中，研究者通常将海洋锋视为 SST 图像中的边缘结构，并通过深度神经网络学习锋面区域的边缘、纹理和空间分布特征。Li 等提出 BEDNet 双向边缘检测网络，并构建 OFDS365 海洋锋数据集，用于海洋锋边缘检测研究^[14]。该方法通过深度特征学习增强网络对海洋锋边缘信息的表达能力，有助于改善锋面边缘不连续、弱锋面不易提取等问题。

在基于语义分割或实例分割的海洋锋检测研究中。相关方法通常将海洋锋识别转化为像素级区域提取问题，与仅判断锋面是否存在或输出粗略位置的方法相比，这类方法能够以像素级形式给出锋区或锋线位置，因此更适合用于海洋锋的精细化识别。国内研究中，曹维东等将 Mask R-CNN 用于海洋锋识别，通过标注海温梯

度图训练模型获得像素级锋面识别结果，并结合自适应梯度阈值对锋面结果进行进一步调整^[15]；任诗鹤等提出基于 U-Net 的海洋锋智能检测模型，提高了锋区和锋面中心线的检测效果^[16]；杨梦等基于 U-Net 设计双输入通道 Y-Net 模型，将 SST 图和 SST 梯度图作为输入，并利用多尺度残差卷积块增强模型对南海温度锋多尺度特征的提取能力^[17]。

在基于轻量化网络或目标检测模型的锋面检测方法。这类方法通常通过轻量化网络结构或目标检测框架实现海洋锋的快速识别与定位。Niu 等提出 SQNet 模型，用于实现海洋锋的快速识别^[18]；Wan 等基于改进 YOLOv11 框架提出动态梯度方向与多尺度融合网络，以提高弱锋面和弯曲锋面的检测能力^[19]。这类研究与本文采用 YOLO11n 进行海洋温度锋目标检测的思路较为接近。

总体来看，深度学习方法能够自动学习海洋温度锋的图像特征，在复杂背景、弱锋面以及多尺度锋面识别方面具有明显优势。但这类方法也存在样本标注成本较高、模型可解释性不足以及对训练数据质量敏感等问题。因此，如何在保证检测精度的同时提高模型轻量化程度和复杂海况适应能力，仍是当前海洋温度锋智能检测研究的重要方向。本文将南海 SST 图像中的海洋温度锋作为目标检测对象，采用 YOLO11n 模型进行检测，以探索轻量化目标检测模型在海洋温度锋自动识别中的应用效果。

1.3 本文主要工作

本研究选取 2022 年 1 月至 6 月南海区域 GHRSSST Level 4 海表温度融合分析产品数据作为实验数据来源，用于构建海洋温度锋检测数据集。数据处理过程中，首先对海表温度数据进行图像化处理，然后利用 Sobel 算子计算海表温度梯度变化，将温度梯度变化明显、呈带状或线状分布的区域作为候选海洋温度锋区域。本文以海表温度梯度突变特征作为锋面识别依据，即当某一区域温度变化较为剧烈，并在空间上表现出连续或半连续的边界特征时，将其判定为可能的海洋温度锋。

在候选锋面区域提取完成后，本文结合 Sobel 算子识别结果与专家经验，对候选区域进行筛选，剔除噪声干扰和不明显的弱边界区域，保留锋面特征较清晰的样本。随后使用标注工具对海洋温度锋区域进行矩形框标注，生成 YOLO 格式的数据标签，将海洋温度锋作为目标检测对象输入 YOLO11n 模型进行训练与检测。模型训练完成后，本文通过精确率、召回率、mAP@0.5、mAP@0.5:0.95 以及检测结果可视化等方式，分析模型对海洋温度锋位置的识别和定位效果。

1.4 本文章节安排

第一章介绍研究背景、研究意义、国内外的研究现状和主要研究内容。第二章介绍数据来源、研究区域、数据预处理、图像裁剪、目标标注和数据集划分。第三

章介绍卷积神经网络、YOLO11n 模型结构、模型评价指标。第四章介绍实验方案、实验结果、检测可视化效果。第五章总结本文工作，并说明研究不足。

2 数据集构建

2.1 研究区域

南海是中国重要的边缘海之一，在海洋资源开发、海上交通运输、气候调节以及海洋生态环境研究等方面具有重要意义。由于南海地处低纬海区，受季风转换、海流运动、黑潮入侵、上升流以及海气相互作用等多种因素共同影响，海表温度时空变化较为明显，容易形成不同尺度和形态的海洋温度锋^[20]。海洋温度锋能够反映海洋动力过程和水团边界特征，因此对南海温度锋进行识别与研究，有助于进一步认识南海海洋环境变化特征，并为海洋监测、渔业资源分析和海洋灾害预警等提供一定参考。

本研究选取的研究区域空间范围为 105°E — 120°E 、 0°N — 20°N 的南海中南部海域。该区域覆盖南海较大范围，受季风、环流、上升流及复杂海陆分布等因素影响，海表温度变化较为活跃，锋面现象相对明显。同时，该区域内可能出现线状、带状以及不规则形态等多种温度锋特征，有利于构建包含不同锋面形态的数据集，提升样本类型的多样性，从而增强模型对不同形态海洋温度锋的学习和识别能力。

2.2 GHR SST Level 4 海表温度数据介绍

本研究使用的数据为多尺度超高分辨率全球四级海表温度数据集（MUR-JPL-L4-GLOB-v4.1），该数据集由美国国家航空航天局喷气推进实验室（NASA JPL）制作并发布，属于全球高分辨率海表温度四级产品（GHR SST Level 4）。该产品融合多源卫星遥感观测和现场观测数据，并通过最优插值等方法生成全球高分辨率海表温度场。其空间分辨率为 0.01° ，约为 1km，能够较细致地反映海表温度的空间变化，可为海洋温度锋等中小尺度海洋现象研究提供数据基础。本文选用的数据时间范围为 2022 年 1 月 1 日至 2022 年 6 月 30 日，数据文件格式为网络通用数据格式第四版（netCDF-4），便于使用 Python 进行海表温度数据读取、区域裁剪和后续处理。本文主要使用数据文件中的分析海表温度变量（analysed_sst），该变量表示分析后的海表温度，单位为开尔文（K），实验处理中需将其转换为摄氏度（ $^{\circ}\text{C}$ ）。图 1 为 2022 年 1 月至 6 月期间南海区域某日海表温度分布样例图。




图 1 2022 年 1-6 月南海海表温度某区域分布样例图

2.3 研究区域数据裁切

2.3.1 数据预处理

数据预处理首先读取.nc4 文件，提取所选择的研究区域内的海面温度数据。为便于后续处理，将温度单位由 K 转换为摄氏度。预处理过程中需要去除陆地区域和无效像元。陆地、缺失值和异常值不参与锋面检测，以减少非海洋区域对结果的影响。将海表温度数据绘制为保留有温度空间分布特征的 SST 图像，用于后续人工筛选和模型训练。具体的流程如图 2 所示。




图 2 数据预处理流程

2.3.2 锋面区域选取保存

海洋温度锋在 SST 图像中通常表现为温度水平梯度较大的带状边缘结构，因此可采用边缘检测方法进行识别^[21,22]。Sobel 算法能够分别计算 SST 图像在水平和垂直方向上的梯度变化，并通过局部加权方式突出温度突变区域，在一定程度上抑制噪声影响。

Sobel 算子是一种常用的边缘检测方法，主要通过计算图像在横向和纵向上的灰度变化，找出变化明显的位置。对于海表温度图像来说，温度变化剧烈的区域通常可能对应温度锋，因此可用 Sobel 算子提取候选锋面区域。Sobel 常用两个 3×3 卷积核分别计算水平和垂直方向梯度。Sobel 算子的公式如下：

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} * A \quad (1)$$

$$G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} * A \quad (2)$$

$$G = \sqrt{G_x^2 + G_y^2} \quad (3)$$

其中，A 表示原始图像，G_x 和 G_y 分别表示水平和垂直方向的梯度，G 表示综合梯度强度。

现在已有研究将 Sobel 算子用于 SST 图像中的海洋锋检测，并证明其能够有效突出锋面边缘特征^[21,22]。刘腾对琼东海域多种锋面检测方法进行对比后指出 Sobel 算法在锋面连续性、完整性、清晰度和噪声抑制方面表现较好^[22]。因此，本文选择 Sobel 算法作为海洋温度锋候选区域提取方法，为后续样本构建和 YOLO 模型训练提供基础。




图 3 候选锋面提取与裁剪流程示意图




图 4 最终保存的 patch 样本图片实例

如图 3 所示，本文采用 Sobel 算子提取海洋温度锋候选区域，首先对 SST 场进行高斯平滑处理，滤波参数设置为 $\sigma=1.2$ 像素，以降低噪声对梯度计算的影响。随后使用标准 3×3 Sobel 卷积核计算 SST 空间梯度。梯度阈值采用动态百分位法确定，即取每幅图像有效海域梯度值的第 97.5 百分位数作为阈值，仅保留梯度最高的约 2.5% 像元作为候选锋面区域，如（a）（b）中所示。候选区域提取后，通过连通域分析删除小于 50 个像素的区域，并采用 61×61 的结构元素对相邻锋面段进行膨胀合并。如果合并后的锋面组满足真实锋面像素数不少于 50 个，则根据锋面端点确定基础范围，如（c）中黄色框中就是对检测到的锋线做最小外接矩形，并按面积扩大系数 3.0 进行扩展，即（c）中绿色矩形框就是进行拓展后的实际裁切范围，裁剪框在连通域四周至少外扩 40 像素，该处理方式能够在保留锋线主体的同时，保存锋线两侧的海温背景信息以保留锋面两侧的海温背景信息。裁剪后进一步依据最大连通域大小、锋面像素占比、长宽比、细长比、端点距离比和填充率等指标进行质量控制，从而筛选出形态较清晰、结构较完整的温度锋样本。

需要说明的是， 1200×1200 像素为裁剪后 patch 图像的保存尺寸，用于保留较清晰的人工筛选和标注信息；模型训练阶段则根据实验设置将图像缩放至 512、640 或 704 输入网络。

样本生成后进行需要进行人工筛选，而不是不依赖脚本自动判断样本是否可用。筛选示例如图 5 左侧所示，筛选时选择的 patch 应该具有以下特征：锋线呈现清晰可辨的带状结构、表现为明显的温度过渡带、在梯度图中对应连续高梯度带。本研究希望通过人工筛选的方式构建的数据集，以进一步减少传统方法的误检结果，提高最终数据集的可靠性。最终经过人工筛选，共获得 470 份南海海洋温度锋面样本 patch 图片。




图 5 筛选示例图，左侧的六张为可用的样本示例，右侧的六张为受干扰的样本示例。

2.4 海洋温度锋目标标注

本研究使用 LabelImg 工具对海洋温度锋图像进行人工标注。LabelImg 是一种常用的图像标注工具，支持通过人工手动绘制矩形框的方式对目标区域进行标注，操作简单直观，适合本实验需要的海洋温度锋目标检测数据集的制作。标注方式为矩形框标注，类别统一设置为 front。标注示例如图 6 所示。

在使用 LabelImg 标注时需要遵守统一的标注原则，以保证数据集的质量以及提高训练样本的一致性：尽量完整地框选锋线；对于形态较长或弯曲明显的锋面，可以根据实际情况分段标注；避免一个矩形框包含过多无关区域；尽量减少误标和漏标。




图 6 海洋温度锋位置标注示例图

LabelImg 可以自动保存 YOLO 模型的可读文件到指定路径的文件夹，即格式的.txt 标签文件。每个标签文件记录目标类别编号、中心点坐标、宽度和高度，且与对应图像文件保持同名。经过人工标注完成后，共获得 470 份标注文件与 470 份海洋温度锋面样本 patch 图片一一对应。用于后续 YOLO 模型训练与验证。

经过人工筛选后，共获得 470 张南海海洋温度锋样本图像。样本均为经过裁剪和筛选后的 SSTpatch 图像。数据集按照约 7.4:1:1 的比例划分为训练集和验证集以及测试集。其中训练集 370 张，验证集 50 张，测试集 50 张。训练集图像文件命名为 0001 至 0370，验证集图像文件命名为 0101 至 0150，测试集图像文件命名为 0001 至 0050。patch 图像文件和标签文件名一一对应，用于后续 YOLO11n 模型训练与验证。

3 YOLO11n 模型简介

3.1 卷积神经网络简介

卷积神经网络（CNN）是一类主要用于图像处理的深度学习模型，如图 7 所示基础卷积神经网络结构，图像先输入到网络中，卷积层会提取图像里的局部特征；ReLU 用来保留有用的特征；池化层会压缩特征图，减少计算量，同时保留主要信息。经过多次卷积和池化后，网络能够得到更深层的图像特征。最后，展平层把这些特征整理成一维数据，全连接层根据这些特征进行综合判断，输出最终结果^[23]。对于海洋温度锋检测来说，CNN 可以帮助模型学习 SST 图像中温度变化明显的区域，为后续识别海洋温度锋提供基础特征。

随着深度学习技术的发展，卷积神经网络模型也逐渐的应用到目标检测、遥感图像识别、医学影像分析和自动驾驶日常生活相关领域^[23]。在海表温度图像中，海洋温度锋通常表现为颜色或温度梯度明显变化的带状区域，因此卷积神经网络可以用于学习锋线边界特征、形态特征、空间分布特征。




图 7 基础卷积神经网络结构示意图

本文采用的 YOLO11n 模型也是以卷积神经网络为基础构建的目标检测模型。首先通过卷积神经网络提取 SST 图像中的温度变化的特征，再结合目标检测结构输出海洋温度锋出现的位置和类别，从而实现对海洋温度锋区域的自动识别。

3.2 YOLO 模型简介

本研究选择 YOLO11n 作为海洋温度锋检测模型。YOLO11n 属于 YOLO 系列中的轻量化目标检测模型，具有参数规模较小、训练速度较快、推理流程清晰的特点。本文数据集规模相对有限，实验主要在个人计算机环境下完成，因此选择 YOLO11n 有利于在保证一定检测能力的同时，降低训练与部署成本。

YOLO11n 是以卷积神经网络为核心构建的目标检测模型。模型网络架构如下图所示。模型整体由 Backbone、Neck 和 Head 三部分组成^[24,25]。在 YOLO11n 的网络结构中，Backbone 主要用于提取输入图像中的边缘、纹理和空间结构等特征，Neck 对不同尺度的特征进行融合，Head 则根据融合后的特征输出检测结果^[24]。在

本文的海洋温度锋检测任务中，模型输入为 SST 图像，输出结果包括温度锋目标的位置、类别和置信度，其中类别为海洋温度锋（front）。

Backbone 是模型的特征提取部分，用于从输入图像中逐层提取由浅到深的特征信息。在海洋温度锋检测任务中，SST 图像中的有效特征主要包括锋线边界、温度过渡带、局部梯度增强区域以及周围背景纹理。**Backbone** 通过卷积运算逐步降低特征图的空间分辨率，并增强特征的语义表达能力，为后续目标定位提供基础。**Neck** 用于进行多尺度特征融合。海洋温度锋在 SST 图像中既可能表现为较长的带状区域，也可能只分布在局部范围内。如果仅依赖单一尺度特征，模型往往难以同时兼顾锋面的整体形态和局部边界细节。**Neck** 通过上采样、特征拼接等方式，将浅层细节信息与深层语义信息结合起来，使模型既能关注锋面边界变化，也能表征较大范围内的温度分布结构。**Head** 是模型的检测输出部分，根据前面提取和融合后的特征生成预测结果，包括温度锋目标的位置、类别和置信度。本文的检测类别只有一类，即海洋温度锋 front。**Head** 输出的内容主要包括预测框位置、目标类别和预测置信度。模型通过这些输出判断图像中是否存在温度锋，并给出其大致出现区域。**Neck** 层和 **Head** 层的结构如下图 9 所示。




图 8 Yolo11n 海洋温度锋检测网络架构图




图 9 多尺度特征融合与检测头结构示意图

总体来看，将 YOLO11n 用于本研究的海洋温度锋检测具有一定的理论可行性，yolo11n 模型能够实现对部分锋面区域的自动定位。该模型的优点是轻量化、训练速度快、检测速度快，适合进行初步自动检测。温度锋在 SST 图像中具有较明显的空间结构特征，适合通过卷积神经网络进行学习，此外在标注样本图片中锋面位置时采用矩形框标注方式，将温度锋出现区域转化为目标检测问题，很好地与 YOLO11n 模型的输出形式对应。

3.3 模型评价指标

为评价 YOLO11n 模型对海洋温度锋的检测效果，本文选取 Precision、Recall、IoU、mAP@0.5 和 mAP@0.5:0.95 作为主要评价指标，相关定义与计算方式在 Kong R 等文献中给出^[26]。Precision 用于衡量模型预测为海洋温度锋的目标中，实际为真实目标的比例；Recall 用于衡量真实存在的海洋温度锋目标中，被模型成功检测出的比例。其计算公式如下：

$$Precision = \frac{TP}{TP + FP} \quad (4)$$

$$Recall = \frac{TP}{TP + FN} \quad (5)$$

(3),(4)式中，TP 表示模型正确检测出的海洋温度锋目标数量，FP 表示模型误检出的目标数量，FN 表示真实存在但未被模型检测出的目标数量。

IoU 用于衡量预测框与真实标注框之间的重合程度，其计算公式如下：

$$IoU = \frac{S_p \cap S_g}{S_p \cup S_g} \quad (6)$$

其中， S_p 表示预测框区域， S_g 表示真实标注框区域。

在目标检测任务中，mAP@0.5 表示 IoU 阈值设定为 0.5 时模型的平均精度均值，常用于评价模型在相对宽松定位条件下的检测效果。mAP@0.5:0.95 表示在 IoU 阈值从 0.5 到 0.95 变化时计算得到的平均精度均值，能够更全面地反映模型在不同定位精度要求下的检测性能。与 mAP@0.5 相比，mAP@0.5:0.95 对预测框与真实框的重合程度要求更高，因此其数值通常低于 mAP@0.5。

此外，本文结合 box_loss、cls_loss 和 dfl_loss 观察模型训练过程中的误差变化。其中，box_loss 主要反映预测框定位误差，cls_loss 反映目标类别判断误差，dfl_loss 用于衡量边界框回归过程中的分布拟合情况。如果各项损失值随着训练轮数增加整体下降并逐渐趋于稳定，通常说明模型参数更新较为有效，训练过程具有一定的收敛趋势。

4 基于深度学习的海洋锋检测方法

4.1 实验环境

本次实验使用开源 yolo11n 模型，该模型的训练与验证均使用 Python3.11.15 作为开发语言，在 PyTorch2.11.0 深度学习框架下完成。本文基于 yolo11n，结合 sobel 算子边缘检测法，探究一种基于深度学习的海洋温度锋检测方法。在使用 sobel 算子检测锋面时，根据设定的阈值将图像中的像素点分为“front”和“background”。超过设定阈值的被归类为温度锋。然后将该锋面区域裁切保存为样本图片，后续经过人工筛选与标注形成数据集。

深度学习模型训练依赖于训练样本的数据量与数据质量。因此本研究通过人工筛选的方式对样本 sst 图片进行数据清洗，标注，最终构建完整的 2022 年 1 月至 6 月南海海洋温度锋面样本数据集，并且数据集按照 7.4:1:1 的比例划分为训练集和验证集以及测试集。其中训练集 370 张，验证集 50 张，测试集 50 张，且图像文件和标签文件保持同名一一对应，保证被 YOLO11n 正确读取。

此外，为了分析不同训练设置对模型训练和检测性能的影响，本研究设计了一项基础实验和三组对比实验。基础实验使用 YOLO11n 预训练权重进行训练，作为后续参数对比实验的参照，该实验主要用于初步验证 YOLO11n 在本文数据集上的可训练性和海洋温度锋检测能力。三组对比实验分别围绕学习率、输入尺寸和 batch size 展开。其中，学习率实验用于比较不同学习率对模型收敛速度和检测指标的影响；输入尺寸实验用于分析不同图像尺寸对检测效果的影响，因为输入尺寸会影响图像细节保留程度，同时也会影响训练速度和显存占用；batch size 实验用于比较不同 batch size 对训练结果的影响，因为 batch size 会影响训练稳定性、显存占用和参数更新频率。

最后，经过基础实验，三组对比实验，确认最佳训练参数后，将会使用 2022 年 1 月至 6 月南海海洋温度锋面样本训练集与验证集对模型进行训练与验证，使用测试集对模型进行测试与评估，根据测试与评估结果评价其实际应用效果。基于 yolo11n 的海洋温度锋检测的具体流程如图 10 所示。




图 10 基于 YOLO11n 的海洋温度锋检测流程图

4.2 基于 yolo11 的海洋锋检测方法

4.2.1 基础实验

训练损失方面，三条训练损失都在下降：

表 1 模型在训练集上的损失

损失指标	第 1 轮	第 30 轮	变化
训练集边界框损失	1.83700	1.58270	下降约 13.8%
训练集分类损失	1.87997	1.52349	下降约 19.0%
训练集分布焦点损失	1.76580	1.59381	下降约 9.7%




图 11 模型在训练集和验证集上的损失变化曲线

从表 1 和图 11 的训练结果可以看出，随着训练轮数增加，模型的训练损失整体呈下降趋势。其中，train/box_loss 由 1.83700 下降到 1.58270，train/cls_loss 由 1.87997 下降到 1.52349，train/df1_loss 由 1.76580 下降到 1.59381。说明模型在训练过程中逐渐学习到了海洋温度锋的图像特征，尤其是分类损失和边框定位损失都有明显下降，预测框定位能力和目标类别判断能力均有所提高。

表 2 模型在验证集上的性能指标

性能指标	第 1 轮	第 30 轮	最好结果
Precision	0.40041	0.67516	第 08 轮 0.71626
Recall	0.68966	0.70690	第 21 轮 0.81330
mAP@0.5	0.45533	0.72663	第 17 轮 0.73980
mAP@0.5:0.95	0.18052	0.33825	第 17 轮 0.34187




图 12 模型在验证集上的性能指标变化曲线图

依据表 2 和图 12 进行分析，从验证集指标来看，模型检测性能整体呈上升趋势。 $mAP@0.5$ 由第 1 轮的 0.45533 提升到第 30 轮的 0.72663，最高达到 0.73980； $mAP@0.5:0.95$ 由 0.18052 提升到 0.33825，最高达到 0.34187。 $Precision$ 最终达到 0.67516， $Recall$ 最终达到 0.70690。虽然训练过程中各项指标存在一定波动，但整体趋势表明模型具有一定的海洋温度锋检测能力。验证集曲线存在波动，但从整体趋势看，模型没有出现明显训练失败，训练过程基本收敛。

4.2.2 学习率变量组对照实验

为了分析学习率对 yolo11n 模型训练效果的影响，本实验分别设置学习率为 0.0004、0.0005 和 0.0006 进行对比实验。对比实验结果如下表 3 和图 13 和图 14。

表 3 不同学习率训练结果对比结果

学习率	轮次	最佳 Precision	最佳 Recall	最佳 $mAP@0.5$	$mAP@0.5:0.95$
0.0004	20	0.61810	0.82759	0.70954	0.32753
0.0005	20	0.65330	0.82759	0.71450	0.33783
0.0006	30	0.71626	0.81330	0.73980	0.34187




图 13 不同学习率下模型最佳验证指标对比




图 14 不同学习率下 mAP 指标变化曲线

根据表 3，图 13，图 14 表明，当学习率由 0.0004 提高到 0.0005 时，模型的 mAP@0.5 和 mAP@0.5:0.95 均有所提升，这表明适当的增大学习率是有助于模型更快的学习海洋温度锋特征。当学习率设置为 0.0006 时，模型取得了三组实验中最高的 mAP@0.5 和 mAP@0.5:0.95，分别为 0.73980 和 0.34187，同时 Precision 最高达到 0.71626，说明在当前实验结果下，学习率 0.0006 表现最好。因此，本实验最终决定选择 0.0006 作为后续实验的学习率参数。

4.2.3 输入尺寸变量组对照实验

为了分析输入图像尺寸对模型检测效果的影响，本实验在学习率为 0.0006、batch size 为 2 的条件下，分别设置输入尺寸为 512、640 和 704 进行对比实验。对比实验结果如下表 4 和图 15 和图 16。

表 4 不同输入尺寸对比结果

Imgsize	最佳 Precision	最佳 Recall	最佳 mAP@0.5	mAP@0.5:0.95
512	0.73382	0.77586	0.75206	0.31936
640	0.69115	0.81034	0.69942	0.31775
704	0.68282	0.79310	0.74626	0.30470




图 15 不同输入尺寸下模型最佳验证指标对比

不同输入尺寸下 mAP 指标变化曲线




图 16 不同输入尺寸下 mAP 指标变化曲线

实验结果表明，不同输入尺寸会对模型检测效果产生一定影响。当输入尺寸为 512 时，模型取得了三组实验中最高的 Precision、mAP@0.5 和 mAP@0.5:0.95，分别为 0.73382、0.75206 和 0.31936，说明 512 尺寸下 yolo11n 模型在本实验中对海洋温度锋的综合检测效果较好。当输入尺寸为 640 时，模型的 Recall 最高，达到 0.81034，说明 640 尺寸下 yolo11n 模型在本实验中海洋温度锋的检出能力较强，漏检情况相对较少。但 mAP@0.5 为 0.69942，低于输入尺寸为 512 和 704 的结果，说明输入尺寸为 640 时的综合定位与检测效果并不是最优。当输入尺寸增大到 704

时，模型的 $mAP@0.5$ 达到 0.74626，接近输入尺寸为 512 时的结果，但 $mAP@0.5:0.95$ 仅为 0.30470，低于其他两组，说明继续增大输入尺寸并没有明显提升模型的精细定位能力。综合 Precision、Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 等指标，输入尺寸为 512 时模型表现相对较好。

4.2.4 batchsize 变量组对照实验

为分析 batch size 对模型训练效果的影响，本实验在学习率为 0.0006、输入尺寸为 640 的条件下，分别设置 batch size 为 1、2 和 4 进行对比实验。对比实验结果如表 5 和图 17 和图 18。

表 5 不同 batch 对比结果

Batch	最佳 Precision	最佳 Recall	最佳 $mAP@0.5$	$mAP@0.5:0.95$
1	0.61190	0.75862	0.60271	0.24978
2	0.69115	0.81034	0.69942	0.31775
4	0.72645	0.77586	0.75219	0.34588




图 17. 不同 batch size 下模型最佳验证指标对比




图 18 不同 batch size 下 mAP 指标变化曲线

对比实验结果表明，不同 batch size 对模型检测性能具有一定影响。当 batch size 为 1 时，模型的最佳 $mAP@0.5$ 为 0.60271，最佳 $mAP@0.5:0.95$ 为 0.24978，整体检测效果相对较低。当 batch size 增大到 2 时，模型性能明显提升，最佳 Recall 达到 0.81034，为三组实验中最高，说明在 batch 设置为 2 时模型对海洋温度锋的检出能力较强，漏检情况相对较少。同时， $mAP@0.5$ 和 $mAP@0.5:0.95$ 分别提升到 0.69942 和 0.31775，说明模型在 batch 设置为 2 条件下综合检测能力有所增强。当 batch size 设置为 4 时，模型取得了三组实验中最高的 Precision、 $mAP@0.5$ 和 $mAP@0.5:0.95$ ，分别为 0.72645、0.75219 和 0.34588。虽然此时的 Recall 低于 batch size 为 2 时的结果，但综合定位精度和检测准确性更好。因此，在当前实验条件下，batch size 为 4 时模型综合表现相对较优。

4.3 实验结果评估

为进一步评价 yolo11n 模型在未参与训练和参数调整数据上的检测效果，本实验使用测试集对最终模型进行测试。使用参数设置为 $lr=0.0006$ ， $imgsz=512$ ，batch=4 时训练保存的最佳权重 best.pt 进行测试。测试结果如下表 6。

表 6 yolo11n 在测试集的指标表现

指标	测试集结果
Precision	0.62458
Recall	0.67692
$mAP@0.5$	0.60208
$mAP@0.5:0.95$	0.26980

测试结果表明，模型在测试集上的 Precision 为 0.62458，Recall 为 0.67692， $mAP@0.5$ 为 0.60208， $mAP@0.5:0.95$ 为 0.26980。这表明模型对测试集中的海洋温度锋具有一定识别能力。若与验证集结果相比测试集指标有所下降，则说明模型在未见样本上的泛化能力仍有提升空间。从各项指标来看，Precision 为 0.62458，说明模型预测出的锋面目标中仍存在一定误检；Recall 为 0.67692，说明模型能够检出部分真实锋面，但仍存在较明显的漏检情况。 $mAP@0.5$ 为 0.60208，说明模型在相对宽松的 IoU 阈值下具备一定的目标定位能力；而 $mAP@0.5:0.95$ 仅为 0.26980，说明在更严格的定位要求下，预测框与真实框的重合程度仍不稳定，模型的精细定位能力有待提高。

综合分析训练结果和测试结果可以得出，YOLO11n 模型经过训练后能够对海表温度图像中的海洋温度锋进行一定程度的自动检测。在验证集上，模型的训练损失整体下降， mAP 等评价指标整体上升，说明模型能够学习到海洋温度锋的颜色变化特征、温度梯度特征和带状结构特征。在测试集上，模型取得了 Precision 为

0.62458、Recall 为 0.67692、mAP@0.5 为 0.60208 和 mAP@0.5:0.95 为 0.26980 的结果，表明模型对未参与训练和验证的新数据样本具有一定的检测能力

为了更直观地展示本实验中 yolo11n 模型对海洋温度锋的检测效果，我选取测试集中检测结果较好的样本进行可视化分析。可视化结果如下方图 19 所示，图中左侧为人工标注结果，右侧为模型检测结果。




图 19 测试集中检测效果较好的样本对比

从图 19 可以看出，模型能够较准确地识别图像中的海洋温度锋区域。对于样本 0039、0040 和 0042，预测框基本覆盖锋面主体位置，说明模型能够学习到温度锋两侧明显的温度差异特征。而在样本 0043、0044 和 0046 中，锋面呈现较明显的条带状结构，模型检测框也能够沿着主要温度过渡区域进行定位，整体检测位置与左侧人工标注的结果接近。图 20 的结果说明，经过训练 YOLO11n 模型对形态较清晰、温度变化较明显的海洋温度锋具有一定的识别能力。模型能够根据 SST 图像中的颜色变化、边界过渡和局部结构特征判断锋面出现的位置，从而实现对海洋温度锋区域的自动检测。不过，部分样本中模型预测框与人工标注框存在一定的偏差，比如预测框范围略大于左侧的人工标注框，说明模型对锋面边界的精细定位能力还有提升空间。

从可视化结果可以看出，对于形态清晰、温度过渡明显的海洋温度锋，模型通常能够给出较稳定的检测结果。在锋面主体较连续、两侧温度差异较明显的样本中，模型预测框通常能够覆盖主要锋面区域，说明 YOLO11n 在一定程度上能够识别 SST 图像中的典型温度锋特征。但在部分样本中，也存在预测框偏大、位置偏移和重复检测等问题，说明模型对锋面边界和目标范围的精细定位能力仍然不足。

为分析模型在检测过程中存在的问题，我选取测试集中出现误检的样本进行可视化对比，如图 20 所示。图中左侧为人工标注结果，右侧为模型检测结果。




图 20 测试集中误检样本对比

从图 20 可以看出，模型在 0004 和 0019 样本中会将非标注区域误判为海洋温度锋。除了检测出人工标注框附近的锋面，模型还在图像中其他温度变化比较明显的位置生成了额外的预测框。比如样本 0033 中，模型在近岸区域和强温度变化区域生成了多个检测框，这说明复杂背景干扰了模型对海洋温度锋出现位置的判断。图 20 的结果说明，误检产生的主要原因是部分非锋面区域在 SST 图像中也表现出明显的颜色变化或梯度变化，这些特征与海洋温度锋的特征具有相似性。尤其是在近岸区域、局部冷暖水团交界处以及温度变化较剧烈的背景中，模型容易将普通温

度梯度或噪声区域识别为锋面目标。因此，误检结果说明模型虽然学习到一定的温度变化特征，但对“真实锋面”和“普通温度变化区域”的区分能力还是需进一步提高。

误检情况主要出现在普通温度梯度明显、近岸背景复杂、局部温度变化剧烈的区域。这些区域在图像上与海洋温度锋具有相似的颜色过渡和边缘变化，容易被模型误判为锋面。

为进一步分析模型在测试集中的漏检情况，我选取部分漏检样本进行可视化对比，如图 21 所示。图中左侧为人工标注结果，右侧为模型检测结果。




图 21 测试集中漏检样本对比

从图 21 的结果中可以看出，模型在样本 0007 和 0030 中未能完整检测出人工标注的海洋温度锋区域。说明人工标注区域内即便存在锋面目标，但模型却没有给出对应预测框，说明模型对部分弱锋面或背景复杂的锋面区域的识别能力不足。而在样本 0020 和 0029 中，模型虽然给出了预测框，但预测位置与人工标注区域明显不一致，真实锋面区域完全没有被模型检测到。根据图 21 的结果分析出漏检产生的原因可能与锋面特征不够明显有关。部分样本中锋面边界较弱，温度过渡不够清晰，或者锋面周围存在较多相似的温度变化区域，使模型难以准确区分真实锋面和

背景变化。对于样本 0007、0020 和 0030 这类背景纹理较复杂的图像，模型更容易受到局部噪声和复杂温度分布影响，从而忽略了人工标注的锋面区域。

漏检情况主要出现在弱锋面、断续锋面和背景纹理复杂的样本中，当锋面边界不够清晰或温度差异不明显时，模型难以稳定识别真实锋面区域。

结论与展望

结论

在这项研究中，本文围绕南海海洋温度锋自动检测问题，完成了海洋温度锋检测数据集构建、YOLO11n 模型训练、参数对比实验和测试集验证等工作。基于南海海表温度数据构建目标检测数据集，并通过学习率、输入尺寸和 batch size 对比实验分析不同参数对模型检测效果的影响。得出以下结论：

（1）本文构建了南海海洋温度锋目标检测数据集。数据集以南海海表温度数据为基础，通过候选锋面区域提取、人工筛选和矩形框标注，形成了可用于 YOLO11n 模型训练与测试的海洋温度锋样本。

（2）YOLO11n 模型能够对海表温度图像中的海洋温度锋进行一定程度的自动检测。实验结果表明，当学习率为 0.0006、输入尺寸为 512、batch size 为 4 时，模型综合表现较好，说明合适的训练参数有助于提高模型对温度锋特征的学习效果。

（3）最终模型在测试集上取得 Precision 为 0.62458、Recall 为 0.67692、mAP@0.5 为 0.60208、mAP@0.5:0.95 为 0.26980 的结果。该结果说明 YOLO11n 对南海海表温度图像中的海洋温度锋具有一定检测能力，也表明深度学习目标检测方法可为海洋温度锋自动化检测提供一种可行思路。

展望

本文完成了基于 YOLO11n 的海洋温度锋检测实验，结果表明该模型对部分海洋温度锋具有一定检测能力，但研究中仍存在一些不足。后续研究可从数据集规模、标注方式和模型结构等方面进行改进：

（1）进一步扩大数据集规模。本文样本主要来源于 2022 年 1 月至 6 月南海区域，时间跨度和空间范围相对有限。后续可引入多季节、多年份和多海域的 SST 数据，增加样本类型和背景条件，从而提升模型对不同季节、不同海域和不同类型温度锋的泛化能力。

（2）改进温度锋标注方式。本文采用矩形框方式标注温度锋目标，虽然能够满足 YOLO 目标检测模型的训练需求，但对于细长、弯曲和断续分布的锋面结构表达仍不够精细。后续可尝试采用分割标注或旋转框检测方法，使模型能够更加准确地描述温度锋形态。

（3）进一步优化模型检测效果。本文模型在弱锋面、近岸复杂背景和局部温度梯度较强区域仍存在误检、漏检和定位偏差问题。后续可尝试改进 YOLO 模型结构，结合传统锋面检测方法或引入注意力机制，以提高海洋温度锋检测的精度和稳定性。

致 谢

本论文是在查国震老师的悉心指导下完成的。从论文的选题方向、研究思路的确定，到实验方案的设计、论文的撰写与修改，正是因为查老师给予耐心细致的指导和慷慨的帮助，我才能够顺利完成本次毕业论文工作。在此，谨向查老师表示衷心的感谢，同时也要感谢校外指导老师吴立宗老师的指导。

此外，还要感谢海洋技术与测绘学院各位老师在本科阶段给予我的教育与培养，使我在专业知识、实践能力和科研思维方面都有了较大提升。同时感谢同学们在学习和论文完成过程中给予的支持与帮助。

最后，感谢家人在学习和生活中给予我的理解、鼓励与陪伴。正是他们的支持，使我能够保持信心，顺利完成本论文。谨向所有关心、帮助过我的老师、同学和家人致以诚挚的谢意。

参 考 文 献

- [1] Cayula, J-F., & Cornillon, P.(1992).Edge Detection Algorithm for SST Images. Journal of Atmospheric and Oceanic Technology, 9(1), 67-80.
- [2] Cayula J F, Cornillon P. Multi-image edge detection for SST images[J]. Journal of Atmospheric and Oceanic Technology, 1995, 12(4): 821-829. DOI: 10.1175/1520-0426(1995)012<0821:MIEDFS>2.0.CO;2. [5] Hopkins J, Challenor P, Shaw A G P. A new statistical modeling approach to ocean front detection from SST satellite images [J]. Journal of Atmospheric and Oceanic Technology, 2010, 27(1): 173-191.
- [3] Belkin I M, O'Reilly J E. An algorithm for oceanic front detection in chlorophyll and SST satellite imagery[J]. Journal of Marine Systems, 2009, 78(3): 319-326.
- [4] 黎安舟,周为峰,范秀梅.遥感图像中尺度海洋锋及涡旋提取方法研究进展[J].中国图象图形学报, 2017, 22(6):10.DOI:10.11834/jig.160637.
- [5] 于杰,管磊.基于 SNPP/VIIRS 卫星数据的海温锋检测算法研究[J].中国海洋大学学报(自然科学版), 2024, 54(09):21-29.DOI:10.16441/j.cnki.hdx.20230141.
- [6] Kirches G, Paperin M, Klein H, Brockmann C, Stelzer K. GRADHIST — A method for detection and analysis of oceanic fronts from remote sensing data[J]. Remote Sensing of Environment, 2016, 181: 264-280. DOI: 10.1016/j.rse.2016.04.009.
- [7] 李阳东, 梁君豪, 笪亨融, 等. 基于直方图分析和 Jensen-Shannon 散度的海表温度锋检测[J]. 海洋测绘, 2022, 42(4): 60-64.
- [8] Hopkins J, Challenor P, Shaw A G P. A new statistical modeling approach to ocean front detection from SST satellite images[J]. Journal of Atmospheric and Oceanic Technology, 2010, 27(1): 173-191.
- [9] 吴曲然, 胡建宇, 孙振宇, 等. 海洋锋面统计模型检测法的改进与验证[J]. 厦门大学学报: 自然科学版, 2015, 54(2): 199-206.
- [10] 平博, 苏奋振, 杜云艳, 孟云闪, 苏伟光. 基于引力模型的海洋锋信息提取[J]. 地球信息科学学报, 2013, 15(2): 187-192.
- [11] 王磊, 王丽娅, 魏皓. 利用卫星遥感资料对南海北部陆架海洋表层温度锋的分析[J]. 中国海洋大学学报: 自然科学版, 2004, 34(3): 351-357.
- [12] 陈彪, 王静, 经志友, 李敏. 琼东和粤西海表温度锋的季节与年际变化特征分析[J]. 热带海洋学报, 2016, 35(5): 1-9.

- [13] Lima E, Sun X, Dong J, Wang H, Yang Y, Liu L. Learning and transferring convolutional neural network knowledge to ocean front recognition[J]. *IEEE Geoscience and Remote Sensing Letters*, 2017, 14(3): 354-358.
- [14] Li Q, Fan Z, Zhong G. BEDNet: Bi-directional Edge Detection Network for Ocean Front Detection[C]//*Neural Information Processing*. Cham: Springer, 2020: 312-319.
- [15] 曹维东, 解翠, 韩冰, 董军宇. 融合深度学习的自动化海洋锋精细识别[J]. *计算机工程*, 2020, 46(10): 266-274.
- [16] 任诗鹤, 韩焱红, 李竞时, 赵亚明, 匡晓迪, 吴湘玉, 杨晓峰. 基于 U-Net 的海洋锋智能检测模型[J]. *空间科学学报*, 2023, 43(6): 1091-1099.
- [17] 杨梦, 孙伟富, 张晓娟, 等. 基于 U-Net 改进的双通道南海海洋温度锋面检测方法研究[J]. *海洋通报*, 2025, 44(4): 458-468.
- [18] Niu R, Tan Y, Ye F, Gong F, Huang H, Zhu Q, Hao Z. SQNet: Simple and fast model for ocean front identification[J]. *Remote Sensing*, 2023, 15(9): 2339.
- [19] Wan X, Zhang L, Ma X, Xu W, Chen Q, Zhao R, Zeng M. Dynamic gradient orientation and multi-scale fusion network for ocean front detection[J]. *Journal of Sea Research*, 2025, 206: 102601.
- [20] Wang Y, Yu Y, Zhang Y, Zhang H.-R, Chai F. Distribution and variability of sea surface temperature fronts in the South China Sea[J]. *Estuarine, Coastal and Shelf Science*, 2020, 240: 106793.
- [21] Olaya F C, Crawford W R, Pérez-Brunius P, et al. Ocean Front Detection with Glider and Satellite-Derived SST Data in the Southern California Current System[J]. *Remote Sensing*, 2021, 13(24): 5032.
- [22] 刘腾. 琼东海洋锋面研究[D]. 青岛: 自然资源部第一海洋研究所, 2024.
- [23] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. *Nature*, 2015, 521(7553): 436-444. DOI: 10.1038/nature14539.
- [24] Jocher G, Qiu J. Ultralytics YOLO11[CP/OL]. 2024. Available: <https://github.com/ultralytics/ultralytics>.
- [25] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection[EB/OL]. arXiv preprint arXiv:2004.10934, 2020.
- [26] Kong R, Liu Z, Wu Y, Fang Y, Kong Y. Intelligent detection of oceanic front in offshore China using EEFD-Net with remote sensing data[J]. *Journal of Marine Science and Engineering*, 2025, 13(3): 618. DOI: 10.3390/jmse13030618.